Отчёт по заданию PrEng. RecSys

Рекомендательные системы: подходы, ограничения и оценка в продакшене

Тема: рекомендательная система для маркетплейса

1. Цель и условия работы

Цель работы — разобраться в подходах к построению рекомендательных систем (RecSys) и их ограничениях на примере маркетплейса: реализовать несколько классических подходов и бизнес-эвристик, выбрать датасет, сравнить модели, оценить уязвимости и проблемы (в том числе в продакшене), описать мониторинг и ожидаемый эффект для бизнеса.

Предметная область — маркетплейс, рекомендации товаров. Она выбрана потому, что на маркетплейсе естественно возникают все типовые блоки рекомендаций: «Вам может понравиться», «С этим товаром покупают», «Похожие товары», «Другие товары бренда», «Популярное», «Недавно покупали».

Весь стек открытый: библиотеки распространяются под свободными лицензиями, датасет находится в открытом доступе. Всё выполняется локально, без GPU, платных подписок и облачных сервисов.

Соответствие пунктов задания разделам отчёта:

Пункт задания	Раздел отчёта
I. Классические подходы (content-based, collaborative user/item-based, hybrid)	5
I. Бизнес-эвристики (популярное, «с этим покупают», бренд, недавние)	5
Развернуть существующее решение, выбрать датасет	2, 3
II-a. Проблемы и ограничения подходов, уязвимости, этика	7
II-b. Проблемы в продакшене	8
III. Оценка в продакшене: мониторинг, ML- и бизнес-метрики	9
Ожидания бизнеса против реальных результатов	9.3
Как улучшить модель	10

1.1. Оборудование и окружение

Компонент	Значение
Оборудование	Apple M4 Pro, 24 ГБ оперативной памяти
Язык и окружение	Python 3.12, изолированное виртуальное окружение
Ускоритель	не используется: все модели обучаются и работают на процессоре

Все числа в отчёте получены прогонами скриптов из репозитория на этой конфигурации. Результаты оценки сохраняются в reports/metrics.csv, reports/data_stats.json и reports/hybrid_weights.json, и скрипт сборки отчёта читает значения прямо из этих файлов:

после повторного прогона оценки отчёт пересобирается одной командой, без ручного переписывания таблиц.

2. Данные

Датасет — Amazon Reviews 2023, категория Video Games, вариант 5-core (каждый пользователь и товар имеет не менее 5 взаимодействий). Использованы файлы Video_Games.csv (47 МБ: пользователь, товар, оценка, время) и meta_Video_Games.jsonl (437 МБ: название, бренд, категории, описание, цена).

Допущение: отзыв = факт покупки (implicit feedback). Оценка не используется как сила сигнала.

Показатель	Значение	Что это значит для RecSys
Покупки / пользователи / товары	814,6 тыс. / 94,8 тыс. / 24,2 тыс.	Небольшой, но реалистичный каталог
Период	1999–2023	Длинная история, сильная смена ассортимента
Плотность матрицы user × item	0,034%	Сильная разреженность
Покупок на пользователя (медиана)	6	У 32% пользователей не больше 5 покупок
Доля покупок топ-1% / топ-20% товаров	19% / 70%	Длинный хвост, риск popularity bias
Товаров с ≤ 10 покупками	45%	Для половины каталога CF почти не работает
Покупки в тесте товаров, которых нет в train	43%	Холодный старт товаров (новые релизы)
Новые пользователи среди тестовых	12%	Холодный старт пользователей
Оценок 1–2 звезды	11%	«Покупка» не значит «понравилось»
Пик покупок	декабрь–январь (22% за 2 месяца)	Сезонность (праздники)
Товаров без описания	27% (без описания и характеристик — 6%)	Ограничение content-based

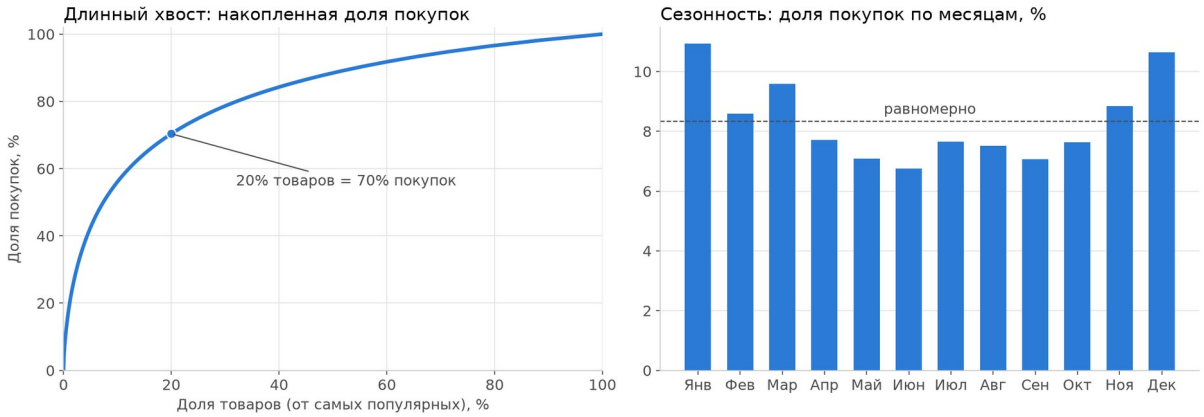


Рисунок 1 — Длинный хвост и сезонность покупок

2.1. Схема валидации

Глобальное разбиение по времени: последние 5% покупок (после 05.08.2022) — тест, остальное — обучение. Модель не видит будущего, и в тест естественно попадают новые пользователи. Релевантными считаются товары, купленные в тестовом периоде, кроме уже купленных ранее. Метрики считаются для K = 10.

Тестовое окно получилось длинным — 13 месяцев (05.08.2022–02.09.2023), и модель за это время не переобучается. Это занижает абсолютные метрики и завышает долю новинок в тесте (см. 7.2). Веса гибрида подбираются на отдельной валидационной выборке: из train отделяются последние 5% покупок (после 26.07.2021), модели обучаются на оставшейся части, и перебором по сетке выбирается комбинация весов с лучшим NDCG@10. Тестовая выборка в подборе не участвует.

3. Архитектура и обоснование стека

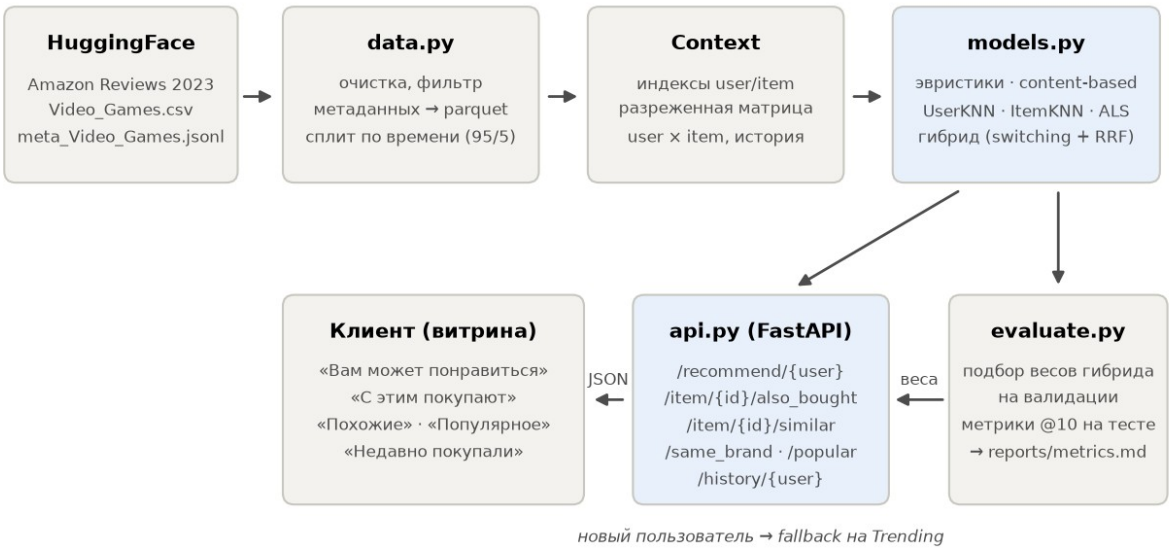


Рисунок 2 — Архитектура решения

3.1. Архитектурный стиль

Выбран модульный пайплайн: данные → подготовка → общий контекст (индексы и матрица user × item) → модели с единым интерфейсом (fit, score, similar) → офлайн-оценка или REST API. Единый интерфейс позволяет одинаково оценивать любую модель и собирать из них гибрид без изменения остального кода.

Оценка и сервис разделены: evaluate.py обучает модели на train и подбирает веса гибрида, а api.py обучает те же модели на всех данных при старте и берёт подобранные веса из reports/hybrid_weights.json.

3.2. Обоснование выбора библиотек

Компонент	Библиотека	Почему именно она
Данные	pandas, pyarrow	Быстрая загрузка, parquet-кэш ускоряет повторные

Компонент	Библиотека	Почему именно она
		запуски
Разреженные матрицы	scipy.sparse	Матрица user × item заполнена на 0,034%, плотная не нужна
Content-based	scikit-learn (TF-IDF)	Простой, интерпретируемый, работает на процессоре за секунды
Collaborative	implicit (ALS, ItemKNN)	Готовая промышленная библиотека для неявного фидбека, сборки под Apple Silicon. Это и есть «развёрнутое существующее решение»
Сервис	FastAPI + uvicorn	Минимальный REST API с автодокументацией (Swagger) для демонстрации блоков витрины
Графики и отчёт	matplotlib, python-docx	Графики и этот отчёт собираются скриптами из сохранённых метрик

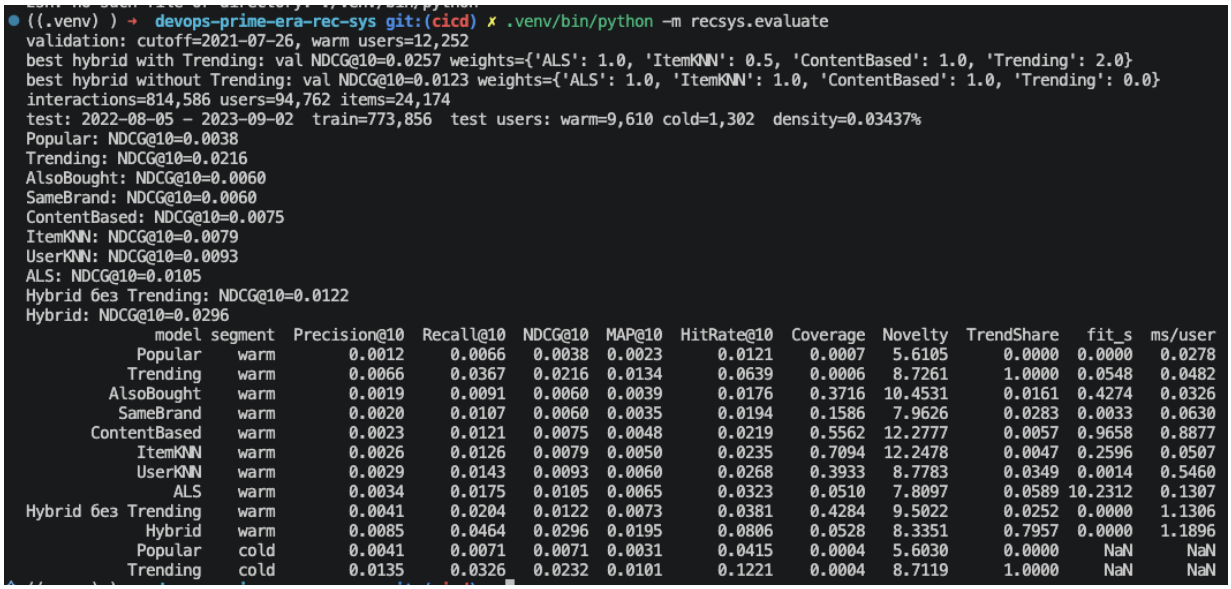
3.3. Что рассматривалось и не вошло

- **LightFM** (гибрид с признаками) — у библиотеки известны проблемы сборки на новых версиях Python и Apple Silicon. Гибрид реализован своими силами.
- **RecTools** — удобная обёртка, но для MVP достаточно implicit и scikit-learn, лишний уровень зависимостей не нужен.
- **Нейросетевые модели** (SASRec, two-tower) — требуют GPU и сильно больше времени на настройку. Для учебного MVP избыточны, упомянуты в разделе 10.
- **Prometheus/Grafana** — задание требует описать мониторинг (раздел 9), а не разворачивать его.

4. Ход работы и зоны ответственности

Этап	Содержание
1	Разбор задания, выбор предметной области (маркетплейс) и плана работ
2	Выбор датасета: сравнение H&M (Kaggle), Retailrocket, Olist и Amazon Reviews 2023. Выбран Amazon Video Games (раздел 6.1)
3	Окружение: Python 3.12 в изолированном виртуальном окружении, установка библиотек
4	Загрузка данных, подготовка, разбиение по времени, расчёт статистики (раздел 2)
5	Бизнес-эвристики: Popular, Trending, AlsoBought, SameBrand, история покупок
6	Content-based (TF-IDF) и коллаборативные модели (UserKNN, ItemKNN, ALS)
7	Гибрид: switching для новых пользователей + смешивание рангов (RRF), подбор весов на валидации
8	Офлайн-сравнение всех моделей и анализ результатов (раздел 5)
9	REST API для демонстрации блоков витрины, проверка всех эндпоинтов
10	Ревью готовой работы и исправление найденных ошибок (разделы 6.2 и 6.3)
11	Разбор проблем подходов и продакшена, метрики мониторинга (разделы 7–9)
12	Отчётность: результаты оценки сохраняются машиночитаемо, отчёт собирается из них скриптом

Работа выполнена индивидуально с помощью ИИ-агента; распределение ролей между участниками не производилось. Как была организована работа с агентом и сколько ресурсов она заняла — в разделе 12.



```
((.venv) ) → devops-prime-era-rec-sys git:(cicd) ✗ .venv/bin/python -m recsys.evaluate
validation: cutoff=2021-07-26, warm users=12,252
best hybrid with Trending: val NDCG@10=0.0257 weights={'ALS': 1.0, 'ItemKNN': 0.5, 'ContentBased': 1.0, 'Trending': 2.0}
best hybrid without Trending: val NDCG@10=0.0123 weights={'ALS': 1.0, 'ItemKNN': 1.0, 'ContentBased': 1.0, 'Trending': 0.0}
interactions=814,586 users=94,762 items=24,174
test: 2022-08-05 – 2023-09-02  train=773,856  test users: warm=9,610 cold=1,302  density=0.03437%
Popular: NDCG@10=0.0038
Trending: NDCG@10=0.0216
AlsoBought: NDCG@10=0.0060
SameBrand: NDCG@10=0.0060
ContentBased: NDCG@10=0.0075
ItemKNN: NDCG@10=0.0079
UserKNN: NDCG@10=0.0093
ALS: NDCG@10=0.0105
Hybrid без Trending: NDCG@10=0.0122
Hybrid: NDCG@10=0.0296
                model segment  Precision@10  Recall@10  NDCG@10  MAP@10  HitRate@10  Coverage  Novelty  TrendShare   fit_s  ms/user
              Popular    warm        0.0012     0.0066   0.0038  0.0023      0.0121    0.0007   5.6105      0.0000  0.0000   0.0278
             Trending    warm        0.0066     0.0367   0.0216  0.0134      0.0639    0.0006   8.7261      1.0000  0.0548   0.0482
           AlsoBought    warm        0.0019     0.0091   0.0060  0.0039      0.0176    0.3716  10.4531      0.0161  0.4274   0.0326
            SameBrand    warm        0.0020     0.0107   0.0060  0.0035      0.0194    0.1586   7.9626      0.0283  0.0033   0.0630
        ContentBased    warm        0.0023     0.0121   0.0075  0.0048      0.0219    0.5562  12.2777      0.0057  0.9658   0.8877
              ItemKNN    warm        0.0026     0.0126   0.0079  0.0050      0.0235    0.7094  12.2478      0.0047  0.2596   0.0507
              UserKNN    warm        0.0029     0.0143   0.0093  0.0060      0.0268    0.3933   8.7783      0.0349  0.0014   0.5460
                  ALS    warm        0.0034     0.0175   0.0105  0.0065      0.0323    0.0510   7.8097      0.0589 10.2312   0.1307
  Hybrid без Trending    warm        0.0041     0.0204   0.0122  0.0073      0.0381    0.4284   9.5022      0.0252  0.0000   1.1306
               Hybrid    warm        0.0085     0.0464   0.0296  0.0195      0.0806    0.0528   8.3351      0.7957  0.0000   1.1896
              Popular    cold        0.0041     0.0071   0.0071  0.0031      0.0415    0.0004   5.6030      0.0000     NaN      NaN
             Trending    cold        0.0135     0.0326   0.0232  0.0101      0.1221    0.0004   8.7119      1.0000     NaN      NaN
```

Рисунок 3 — Вывод офлайн-оценки: подбор весов гибрида на валидации и сравнение моделей на тесте

5. Часть I: реализованные подходы и результаты

5.1. Подходы

Группа	Подход	Как работает	Блок на витрине
Эвристика	Popular	Самые продаваемые товары за всё время	«Популярное», fallback
Эвристика	Trending	Популярность с затуханием по времени (период полураспада 30 дней)	«Популярное сейчас», fallback для новых пользователей
Эвристика	AlsoBought	Пары товаров, купленные одним человеком в пределах 30 дней. Делим на корень популярности, чтобы хиты не попадали к каждому товару	«С этим товаром покупают»
Эвристика	SameBrand	Популярные товары брендов, которые пользователь уже покупал	«Другие товары бренда»
Эвристика	История	Последние купленные товары	«Недавно покупали»
Content-based	TF-IDF	Векторы по названию, бренду, категориям, описанию. Профиль пользователя — взвешенная сумма векторов последних покупок	«Похожие товары»
Collaborative	UserKNN	50 самых похожих покупателей (косинусная мера), рекомендуем их покупки	—
Collaborative	ItemKNN	Похожие товары по векторам покупателей (implicit)	—
Collaborative	ALS	Матричная факторизация для неявного фидбека, 64 фактора (implicit)	—
Hybrid	Switching + RRF	Нет истории → Trending. Есть история → смешивание рангов ALS, ItemKNN, Content и Trending через Reciprocal Rank Fusion	«Вам может понравиться»

Для смешивания выбран Reciprocal Rank Fusion: каждая модель голосует позицией товара в своей выдаче (вес / (60 + позиция)). Скоры разных моделей несравнимы между собой (косинус, скалярное произведение факторов, счётчики), а позиции сравнимы. Уже купленные товары исключаются до отбора кандидатов каждой модели. Веса, подобранные на валидации: ALS 1,0, ItemKNN 0,5, ContentBased 1,0, Trending 2,0 (для варианта без Trending — ALS 1,0, ItemKNN 1,0, ContentBased 1,0).

5.2. Результаты офлайн-оценки

Пользователи с историей (9 610 человек), K = 10:

Модель	Recall@10	NDCG@10	HitRate@10	Coverage	Novelty	TrendShare	мс
Popular	0,007	0,004	0,012	0,07%	5,6	0%	0,03
Trending	0,037	0,022	0,064	0,06%	8,7	100%	0,05
AlsoBought	0,009	0,006	0,018	37%	10,5	2%	0,03
SameBrand	0,011	0,006	0,019	16%	8,0	3%	0,06
ContentBased	0,012	0,007	0,022	56%	12,3	1%	0,89
ItemKNN	0,013	0,008	0,024	71%	12,2	0%	0,05
UserKNN	0,014	0,009	0,027	39%	8,8	3%	0,55
ALS	0,018	0,011	0,032	5%	7,8	6%	0,13
Hybrid без Trending	0,020	0,012	0,038	43%	9,5	3%	1,13
Hybrid	**0,046**	**0,030**	**0,081**	**5%**	**8,3**	**80%**	**1,19**

мс — время построения рекомендаций на одного пользователя.

Новые пользователи (1 302 человека, истории нет, работают только неперсональные модели): Popular NDCG@10 = 0,007, Trending = 0,023.

Coverage — доля каталога, которая хотя бы раз попала в рекомендации. **Novelty** — средняя «неожиданность» товара, −log2 доли купивших (чем выше, тем менее заезжен товар). **TrendShare** — доля выдачи из топ-30 Trending: насколько «персональная» выдача совпадает с общей для всех.

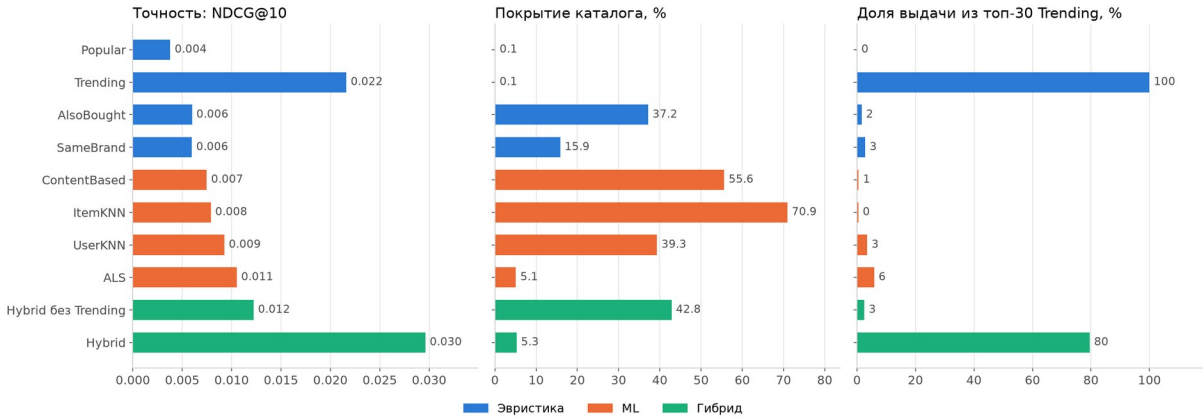


Рисунок 4 — Точность, покрытие каталога и доля Trending в выдаче по моделям

Выводы:

1. Простая эвристика Trending обходит каждую ML-модель по отдельности: в играх спрос сосредоточен вокруг свежих релизов. Любую модель надо сравнивать с сильным бейзлайном, а не с нулём.

2. Среди ML-моделей точнее всех ALS. UserKNN точнее ItemKNN, ItemKNN зато покрывает больше каталога.
3. Гибрид даёт +37% NDCG к Trending, но покрытие падает с 43% (гибрид без Trending) до 5%: точность куплена ценой разнообразия.
4. Гибрид персонализирован слабо: в среднем 8 из 10 его рекомендаций — товары из топ-30 Trending (TrendShare 80%). По сути это Trending, в который ML-модели подмешивают пару персональных позиций, и прирост NDCG даёт в основном «свежесть», а не персонализация (см. 7.4).
5. Абсолютные значения низкие (HitRate 8%). Для каталога в 24,2 тыс. товаров при плотности 0,03% это нормально, важно относительное сравнение.

5.3. Демонстрация сервиса

Сервис поднимается командой uvicorn recsys.api:app и при старте обучает модели на всех данных (около минуты). Каждому блоку витрины соответствует свой эндпоинт.

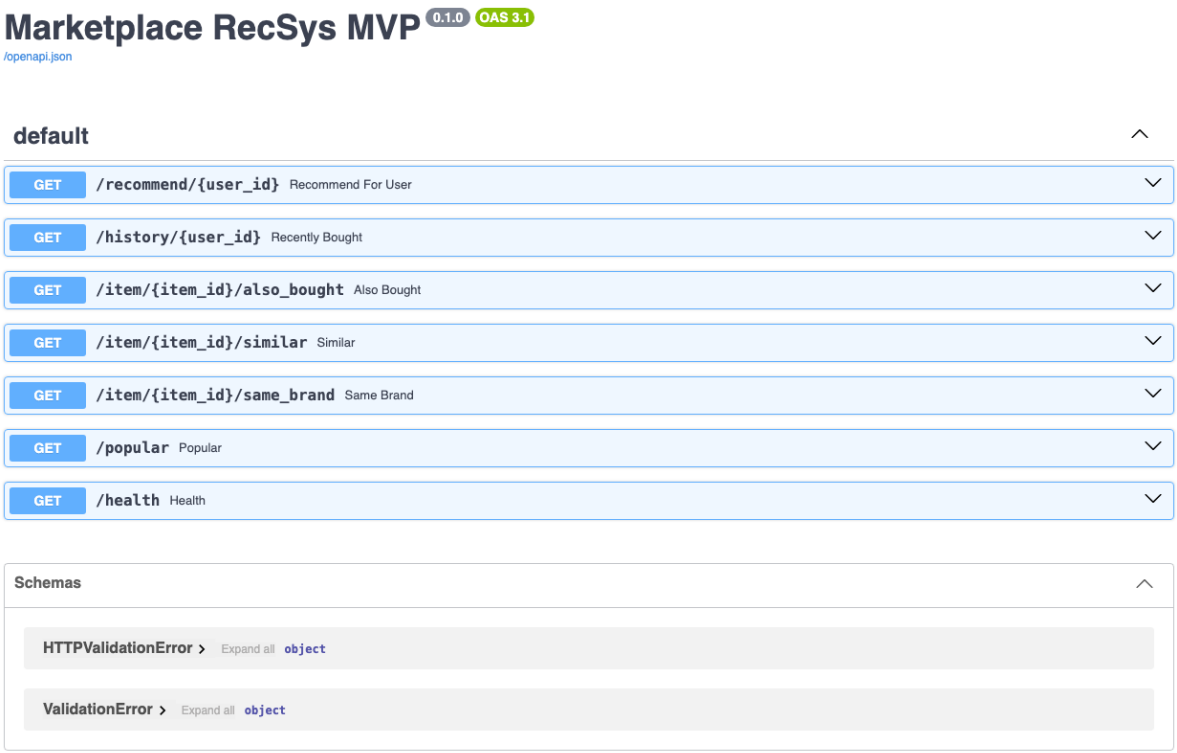


Рисунок 5 — Эндпоинты REST API (Swagger UI)

Для демонстрации персональной выдачи взят пользователь AHZUR65AQ7QWJ5BFBZFHBJIYSRPQ. В его истории — старые игры для Wii и Xbox 360 (рисунок 6), а гибрид рекомендует ему геймпад PS5, Zelda и аксессуары для Switch: 9 из 10 позиций совпадают с Trending (рисунок 7). Это наглядная иллюстрация popularity bias из раздела 7.4.

```
GET /history/AHZUR65AQ7QWJ5BFBZFHBJIYSRPQ?k=10
```



```
{
  "items": [
    {
      "item_id": "B008KVDE7M",
      "title": "NASCAR The Game: Inside Line – Nintendo Wii",
      "brand": "ACTIVISION",
      "category": "Legacy Systems",
      "price": 49.99
    },
    {
      "item_id": "B0086VPUHI",
      "title": "Grand Theft Auto V: Premium Edition – Xbox One [Digital Code]",
      "brand": "Rockstar Games",
      "category": "Xbox One",
      "price": 15
    },
    {
      "item_id": "B003KVLGBI",
      "title": "Lucha Libre Heroes Del Ring – Xbox 360",
      "brand": "Konami",
      "category": "Legacy Systems",
      "price": 42.99
    },
    {
      "item_id": "B0088TN7BO",
      "title": "LEGO Lord of the Rings – Nintendo 3DS",
      "brand": "WB Games",
      "category": "Legacy Systems",
      "price": 19.95
    },
    {
      "item_id": "B07X2H4KDG",
      "title": "WB Games Lego Batman 2: DC Super Heroes – Xbox 360",
      "brand": "WB Games",
      "category": "Legacy Systems",
      "price": 21.94
    },
    {
      "item_id": "B003JVKHEQ",
      "title": "Call of Duty: Black Ops – Xbox 360",
      "brand": "ACTIVISION",
      "category": "Legacy Systems",
      "price": 37.89
    },
    {
      "item_id": "B002I0HCNI",
      "title": "Kinect Star Wars – Xbox 360",
      "brand": "LucasArts",
      "category": "Legacy Systems",
      "price": 14.93
    },
    {
      "item_id": "B004ZX745W",
      "title": "Assassin's Creed: Revelations",
      "brand": "Ubisoft",
      "category": "Legacy Systems",
      "price": 9.98
    },
    {
      "item_id": "B005GISPUS",
      "title": "Jimmie Johnson's Anything With An Engine – Nintendo Wii",
      "brand": "Konami",
      "category": "Legacy Systems",
      "price": 8.36
    },
    {
      "item_id": "B0030H8I4K",
      "title": "Batman: Arkham Origins Collectible Case for PS3",
      "brand": "WB Games",
      "category": "Legacy Systems",
      "price": 92.97
    }
  ]
}
```


Рисунок 6 — Блок «Недавно покупали»: история демонстрационного пользователя

```
GET /recommend/AHZUR65AQ7QWJ5BFBZFHBJIYSRPQ?k=10
```

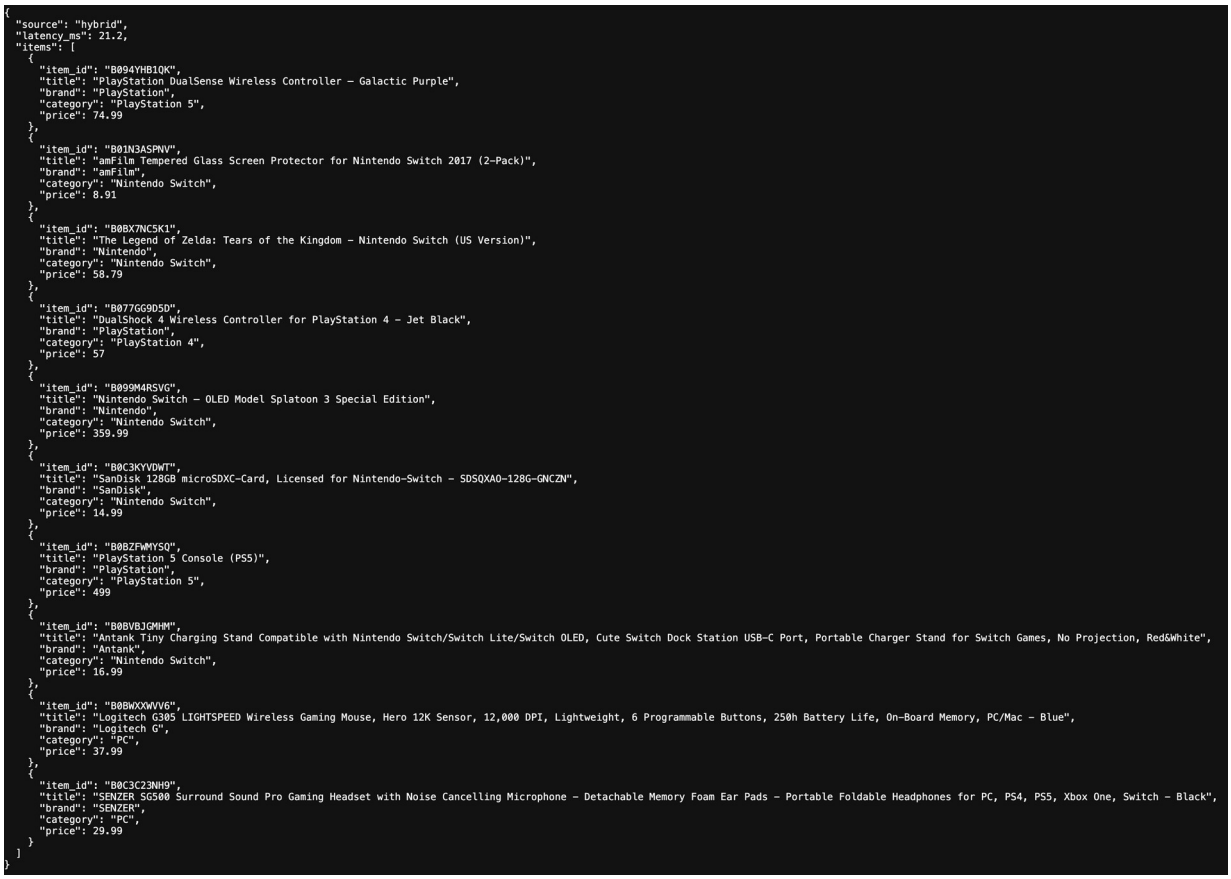
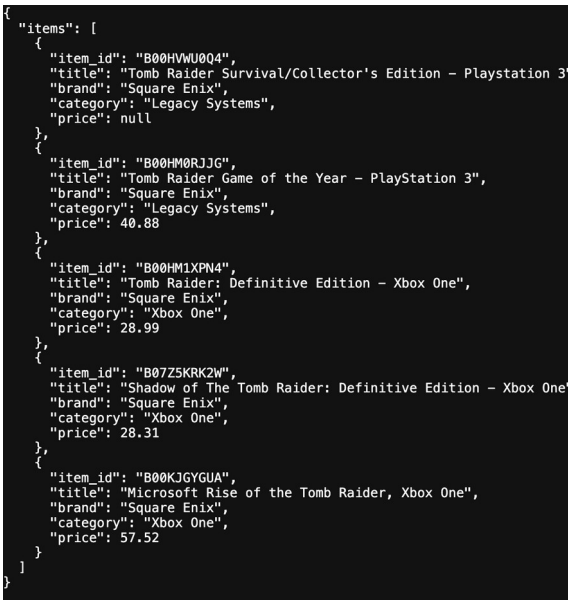


Рисунок 7 — Ответ /recommend для того же пользователя: source = hybrid, но выдача почти совпадает с Trending

Блоки на карточке товара показаны на примере Tomb Raider (B004HD55VK). «Похожие товары» (content-based) возвращают другие издания той же игры — это замены и пример переспециализации из раздела 7.5. «С этим покупают» (AlsoBought) возвращает другие шутеры того же периода — BioShock Infinite, Crysis 3, Far Cry 3, то есть дополнения к покупке.

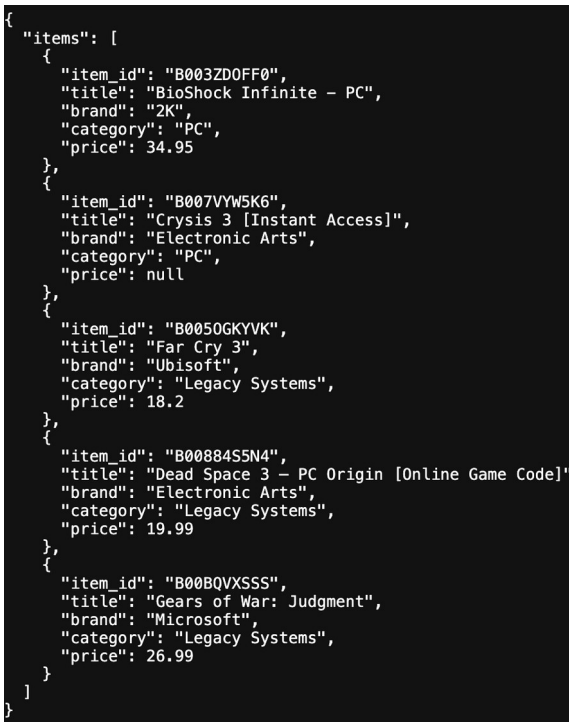
```
GET /item/B004HD55VK/similar?k=5
```



```
{
  "items": [
    {
      "item_id": "B00HVWU0Q4",
      "title": "Tomb Raider Survival/Collector's Edition - Playstation 3",
      "brand": "Square Enix",
      "category": "Legacy Systems",
      "price": null
    },
    {
      "item_id": "B00HM0RJJG",
      "title": "Tomb Raider Game of the Year - PlayStation 3",
      "brand": "Square Enix",
      "category": "Legacy Systems",
      "price": 40.88
    },
    {
      "item_id": "B00HM1XPN4",
      "title": "Tomb Raider: Definitive Edition - Xbox One",
      "brand": "Square Enix",
      "category": "Xbox One",
      "price": 28.99
    },
    {
      "item_id": "B07Z5KRK2W",
      "title": "Shadow of The Tomb Raider: Definitive Edition - Xbox One",
      "brand": "Square Enix",
      "category": "Xbox One",
      "price": 28.31
    },
    {
      "item_id": "B00KJGYGUA",
      "title": "Microsoft Rise of the Tomb Raider, Xbox One",
      "brand": "Square Enix",
      "category": "Xbox One",
      "price": 57.52
    }
  ]
}
```


Рисунок 8 — Блок «Похожие товары» (content-based) для Tomb Raider

```
GET /item/B004HD55VK/also_bought?k=5
```



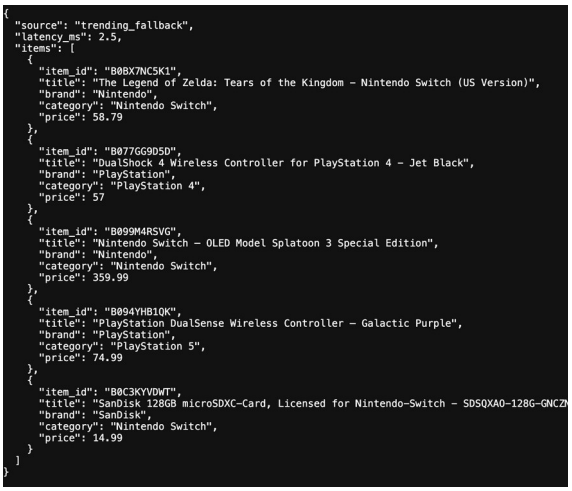
```
{
  "items": [
    {
      "item_id": "B003ZDOFF0",
      "title": "BioShock Infinite - PC",
      "brand": "2K",
      "category": "PC",
      "price": 34.95
    },
    {
      "item_id": "B007VYW5K6",
      "title": "Crysis 3 [Instant Access]",
      "brand": "Electronic Arts",
      "category": "PC",
      "price": null
    },
    {
      "item_id": "B005OGKYVK",
      "title": "Far Cry 3",
      "brand": "Ubisoft",
      "category": "Legacy Systems",
      "price": 18.2
    },
    {
      "item_id": "B00884S5N4",
      "title": "Dead Space 3 - PC Origin [Online Game Code]",
      "brand": "Electronic Arts",
      "category": "Legacy Systems",
      "price": 19.99
    },
    {
      "item_id": "B00BQVXSSS",
      "title": "Gears of War: Judgment",
      "brand": "Microsoft",
      "category": "Legacy Systems",
      "price": 26.99
    }
  ]
}
```


Рисунок 9 — Блок «С этим товаром покупают» (AlsoBought) для Tomb Raider

Для нового пользователя /recommend возвращает "source": "trending_fallback" (рисунок 10). Так реализован switching-гибрид, решающий холодный старт.

Параметр k проверяется (от 1 до 100): неверное значение возвращает понятную ошибку 422, а не 500 (рисунок 11).

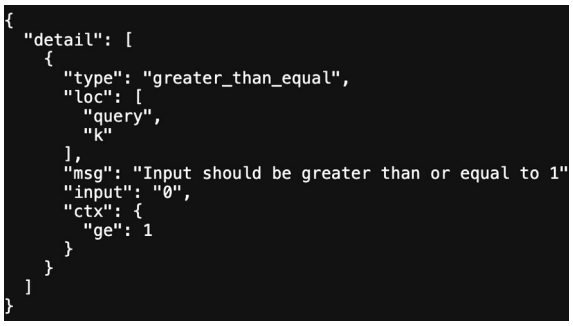
```
GET /recommend/new_user_123?k=5
```



```
{
  "source": "trending_fallback",
  "latency_ms": 2.5,
  "items": [
    {
      "item_id": "B0BX7NC5K1",
      "title": "The Legend of Zelda: Tears of the Kingdom - Nintendo Switch (US Version)",
      "brand": "Nintendo",
      "category": "Nintendo Switch",
      "price": 58.79
    },
    {
      "item_id": "B077GG9D5D",
      "title": "DualShock 4 Wireless Controller for PlayStation 4 - Jet Black",
      "brand": "PlayStation",
      "category": "PlayStation 4",
      "price": 57
    },
    {
      "item_id": "B099M4R5VG",
      "title": "Nintendo Switch - OLED Model Splatoon 3 Special Edition",
      "brand": "Nintendo",
      "category": "Nintendo Switch",
      "price": 359.99
    },
    {
      "item_id": "B094YHB1QK",
      "title": "PlayStation DualSense Wireless Controller - Galactic Purple",
      "brand": "PlayStation",
      "category": "PlayStation 5",
      "price": 74.99
    },
    {
      "item_id": "B0C3KYVDWT",
      "title": "SanDisk 128GB microSDXC-Card, Licensed for Nintendo-Switch - SDSQXAO-128G-GNCZN
      "brand": "SanDisk",
      "category": "Nintendo Switch",
      "price": 14.99
    }
  ]
}
```


Рисунок 10 — Новый пользователь получает Trending (switching-гибрид, холодный старт)

```
GET /popular?k=0
```



```
{
  "detail": [
    {
      "type": "greater_than_equal",
      "loc": [
        "query",
        "k"
      ],
      "msg": "Input should be greater than or equal to 1"
      "input": "0",
      "ctx": {
        "ge": 1
      }
    }
  ]
}
```


Рисунок 11 — Ошибка валидации параметра k

6. Возникшие проблемы и их решения

6.1. Данные и окружение

Проблема	Решение
Изначально выбранный датасет H&M (Kaggle) требует регистрации и принятия правил соревнования, API-ключа Kaggle не было	Выбран открытый Amazon Reviews 2023: тоже маркетплейс, есть метаданные товаров, скачивается без регистрации
Основной сервер датасета не отвечал	Использовано зеркало на HuggingFace
Системный Python 3.14 слишком новый для ML-библиотек	Отдельное виртуальное окружение на Python 3.12
Файл метаданных 437 МБ, большая часть товаров не нужна	Построчное чтение с фильтром по нужным товарам, результат кэшируется в parquet. Повторный запуск — секунды

6.2. Оценка и модели

Проблема	Решение
Риск нечестной оценки при случайном разбиении (утечка будущего)	Глобальное разбиение по времени
Неперсональная эвристика Trending оказалась лучше всех ML-моделей	Trending добавлен в гибрид компонентом «свежести». Итог: +37% NDCG к Trending
Скоры моделей несравнимы, простое сложение не работает	Смешивание по позициям (Reciprocal Rank Fusion) вместо скоров
Гибрид в основном повторяет Trending: 80% выдачи из топ-30 Trending, покрытие 5%	Добавлена метрика TrendShare, проблема зафиксирована как popularity bias, предложены решения (разделы 7.4 и 10)
43% тестовых покупок — товары, которых не было в обучении: CF их не видит, а офлайн-оценка их отбрасывает	Зафиксировано как ограничение, предложены решения (разделы 7.2 и 10)
В первой версии веса гибрида подбирались на тестовой выборке, результат был завышен	Подбор весов вынесен на валидацию (последние 5% train). Веса сохраняются в reports/hybrid_weights.json, API берёт их оттуда
Уже купленные товары занимали места среди кандидатов компонент гибрида (у ALS ~5 из 200)	Фильтр купленного перенесён до отбора кандидатов

6.3. Сервис

Проблема	Решение
API падал с ошибкой 500 при k=100000 и возвращал почти весь каталог при отрицательном k	Проверка параметра k (1–100), неверное значение → 422

7. Часть II-а: проблемы и ограничения подходов

7.1. Холодный старт пользователя (все персональные модели)

- **Проблема:** 12% тестовых покупателей новые. CF и content-based им ничего не дают.

- **Решение:** switching на Trending (реализовано), онбординг-опрос (любимые платформы и жанры), контекст (страница входа, рекламная кампания, гео, устройство), быстрая адаптация по первым кликам в сессии.
- **Проблема решения:** Trending не персонален. Опрос добавляет шаг и увеличивает отток на старте.
- **Обсуждение:** best practice — не заставлять, а предлагать: опрос в 1–2 клика с кнопкой «пропустить», выдача по популярности с учётом контекста и сессионные модели, которые персонализируют уже после 2–3 действий.

7.2. Холодный старт товара (CF: ItemKNN, UserKNN, ALS, AlsoBought)

- **Проблема:** 43% покупок тестового периода — товары, которых не было в обучении (новые релизы). CF их не видит вообще. Офлайн-оценка такие покупки отфильтровывает и тем самым завышает реальное качество.
- **Решение:** content-based по атрибутам (реализован: похожесть считается по описанию, история покупок товара не нужна; в MVP каталог ограничен товарами с покупками, но для нового товара достаточно векторизовать его карточку), гибридные модели с признаками товаров (LightFM, two-tower), квота показов для новинок (exploration, многорукие бандиты).
- **Проблема решения:** у 27% товаров нет описания (нет ни описания, ни характеристик — у 6%), для них остаются название и бренд, и content-based слабее. Квота новинок отнимает показы у проверенных хитов, а значит и краткосрочную выручку.
- **Обсуждение:** стандарт — двухстадийная схема: кандидаты из нескольких источников, включая content и новинки, затем ранжирование. Отдельно — контроль качества карточек товара у продавцов (без описания хуже ранжируется).

7.3. Разреженность данных (CF)

- **Проблема:** плотность 0,034%, у 32% пользователей ≤ 5 покупок, у 45% товаров ≤ 10 покупок. Оценки близости шумные.
- **Решение:** добавить более частые сигналы (просмотры, добавления в корзину, избранное) с разными весами; факторизация (ALS) вместо прямых kNN-соседей.
- **Проблема решения:** неявные сигналы шумные: просмотр ≠ интерес, случайный клик ≠ намерение купить.
- **Обсуждение:** веса по типу события (покупка > корзина > просмотр), учёт времени просмотра, фильтр ботов.

7.4. Popularity bias и длинный хвост (Popular, Trending, ALS, Hybrid)

- **Проблема:** 70% покупок приходится на 20% товаров. Модели воспроизводят и усиливают это: Trending покрывает 0,06% каталога, гибрид — 5%, и 80% его выдачи — товары из топ-30 Trending, то есть большинству пользователей он отдаёт почти «то же, что всем». Пример из API (рисунки 6–7): пользователю, который покупал игры для Wii и Xbox 360, гибрид рекомендует геймпад PS5, Zelda и стекло для Switch. Для маркетплейса это ещё и проблема продавцов: малые продавцы не получают показов.

- **Решение:** штраф за популярность, переранжирование на разнообразие (MMR, квоты по категориям и продавцам), фильтры по контексту (платформа пользователя).
- **Проблема решения:** офлайн-точность падает: наш гибрид без Trending разнообразнее (coverage 43%, TrendShare 3%), но NDCG на 59% ниже.
- **Обсуждение:** баланс задаётся бизнес-целью. Обычная практика — отслеживать coverage, novelty и долю длинного хвоста рядом с точностью и решать A/B-тестом. Офлайн-метрики систематически переоценивают популярное.

7.5. Пузырь фильтров и переспециализация (Content-based, SameBrand)

- **Проблема:** купил Tomb Raider — получаешь пять изданий Tomb Raider (рисунок 8). Мало неожиданных находок.
- **Решение:** подмешивать рекомендации CF или исследовательские слоты, дедуплицировать издания одного тайтла.
- **Проблема решения:** часть исследовательских рекомендаций будет нерелевантна.
- **Обсуждение:** разделять блоки по назначению («Похожие» и «Вам может понравиться») и ограничивать долю одного бренда или серии в выдаче.

7.6. Взаимозаменяемые и уже купленные товары (все модели)

- **Проблема:** купил консоль — система предлагает ещё консоли (то же для геймпадов, карт памяти). Повторные покупки товаров длительного пользования маловероятны, а повторные покупки расходников нормальны.
- **Решение:** фильтр уже купленного (реализован), правила «после покупки X предлагать комплементарные товары» (AlsoBought частично это делает), разметка категорий: длительного пользования или расходник.
- **Проблема решения:** нужна ручная или полуавтоматическая разметка, правила устаревают.
- **Обсуждение:** различать «замены» (похожие) и «дополнения» (с этим покупают), использовать каждый тип на своей странице. Разница хорошо видна на рисунках 8 и 9.

7.7. Неявный фидбек без негатива (все модели)

- **Проблема:** 11% «покупок» оценены на 1–2 звезды, но модель считает их положительным сигналом. Отсутствие покупки тоже не означает «не нравится».
- **Решение:** веса по рейтингу или возвратам, исключение возвратов, отдельный учёт «скрыть рекомендацию».
- **Проблема решения:** явных оценок мало, они смещены (пишут в основном очень довольные или очень недовольные).
- **Обсуждение:** использовать возвраты и кнопку «не интересно» как явный негатив, остальное оставлять implicit.

7.8. Сезонность и дрейф (все модели, особенно ALS и kNN)

- **Проблема:** пик в декабре–январе, спрос смещается к новым релизам. Модель, обученная месяц назад, устаревает.

- **Решение:** затухание по времени (Trending), регулярное переобучение, признаки сезона в ранжировщике.
- **Проблема решения:** частое переобучение стоит денег и рискует выкатить сломанную модель.
- **Обсуждение:** переобучать по расписанию с проверкой качества перед выкаткой, свежие сигналы подмешивать онлайн.

7.9. Масштабируемость (UserKNN, Content-based)

- **Проблема:** UserKNN на каждый запрос сравнивает пользователя со всеми остальными (~0,5 мс на пользователя на 94,8 тыс. пользователей, а на миллионах это секунды). Content-based считает близость ко всему каталогу.
- **Решение:** ItemKNN или ALS (матрица похожих товаров считается заранее), приближённый поиск соседей (FAISS, HNSW), предрасчёт.
- **Проблема решения:** приближённый поиск теряет часть точности, а предрасчёт устаревает.
- **Обсуждение:** user-based в индустрии почти не используют в чистом виде. Стандарт — item-to-item и эмбеддинги + ANN.

7.10. Этические проблемы (AlsoBought, «люди также покупают»)

- **Проблема:** без фильтрации «с этим покупают» и персональная выдача показывают неуместные связи. Примеры: Amazon в 2017 году предлагал вместе покупать компоненты для взрывчатки, а Target по покупкам вычислил беременность подростка раньше её семьи. В нашем каталоге — игры с рейтингом Mature, которые могут попасть детскому аккаунту. Также лутбоксы и внутриигровая валюта (близко к азартным играм) и продвижение собственных товаров площадки в ущерб продавцам.
- **Решение:** список чувствительных категорий и запрещённых связок, фильтр по возрастному рейтингу и возрасту аккаунта, запрет выводов о чувствительных характеристиках (здоровье, беременность, ориентация), аудит выдачи, прозрачность («почему мне это показали»).
- **Проблема решения:** ручные списки всегда неполны, фильтры режут и легитимные рекомендации, аудит дорогой.
- **Обсуждение:** правила + выборочная ручная проверка + жалобы пользователей как сигнал. Для маркетплейса это ещё и регуляторика: защита персональных данных (152-ФЗ / GDPR), антимонопольные требования к self-preferencing, DSA в ЕС.

7.11. Уязвимости: манипуляции и утечки (CF, AlsoBought)

- **Проблема:** (1) **Shilling / data poisoning.** Наш датасет — отзывы, а накрутка отзывов — известная проблема маркетплейсов. Продавец с сотней фейковых аккаунтов, покупающих его товар вместе с хитом, попадает в «с этим покупают» хита. AlsoBought требует всего 2 совместные покупки (min_support=2), такая атака дешёвая. (2) **Утечка приватности.** По изменениям публичных списков «с этим покупают» можно восстановить покупки конкретного человека.

- **Решение:** учитывать только верифицированные покупки, антифрод (новые аккаунты, аномальные всплески), ограничить вклад одного пользователя, повысить порог поддержки, добавить шум или задержку в публичные блоки.
- **Проблема решения:** антифрод даёт ложные срабатывания, высокий порог ухудшает холодный старт, шум снижает точность.
- **Обсуждение:** вклад каждого аккаунта взвешивать по «доверию», мониторить резкие изменения в топах, обновлять публичные блоки батчами.

8. Часть II-b: проблемы в продакшене

Проблема	Решение	Проблема решения	Обсуждение / best practice
Медленный ответ. Гибрид считает 4 модели по всему каталогу (~1,2 мс/пользователь здесь, на миллионах товаров — сотни мс)	Предрасчёт рекомендаций офлайн → кэш (Redis), ANN-индекс для эмбеддингов	Выдача не учитывает действия в текущей сессии	Гибрид: офлайн-кандидаты + лёгкое онлайн-ранжирование. Бюджет латентности p99 < 100 мс
Падение сервиса рекомендаций	Fallback на Trending (реализовано для новых пользователей), таймауты, circuit breaker	Fallback неперсонален, просадка конверсии незаметна без мониторинга	Пустой блок хуже популярного. Отслеживать долю fallback-ответов
Устаревание модели	Переобучение по расписанию (ALS у нас 10 с, на реальном каталоге — часы)	Стоимость, риск выкатить сломанную модель	Проверка метрик перед выкаткой, shadow/canary-релиз, быстрый откат
Рекомендация отсутствующих товаров	Постфильтр по остаткам и статусу карточки в реальном времени	Если фильтр вычеркнул много, выдача короткая	Брать с запасом (top-50 → фильтр → top-10)
Расхождение признаков при обучении и в проде (training/serving skew)	Общий код признаков, feature store	Сложность инфраструктуры	Логировать признаки, с которыми был сделан прогноз, и обучаться на них
Петля обратной связи и position bias. Модель учится на кликах по собственным рекомендациям	Логировать позицию показа, 1–5% трафика со случайной/exploration-выдачей	Exploration-трафик зарабатывает меньше	Без него модель всё сильнее сужает каталог (см. popularity bias)
Расхождение офлайн- и онлайн-метрик	A/B-тест каждого изменения	Нужен трафик и время (2–4 недели)	Офлайн — фильтр для кандидатов в A/B, решение — только по онлайну
Качество данных (дубли, боты, сломанный ETL)	Валидация данных на входе пайплайна, фильтр ботов	Ложные срабатывания проверок	Алерт при резком изменении объёма или распределения событий
Масштабирование (миллионы пользователей и товаров)	Item-based / эмбеддинги вместо user-based, шардирование, батч-инференс	Стоимость инфраструктуры	Считать стоимость рекомендации против прироста выручки

9. Часть III: оценка работы в продакшене

9.1. Уровни метрик

Уровень	Метрики	Когда и как
Офлайн ML	Precision/Recall/NDCG/MAP/HitRate@K, Coverage, Novelty, TrendShare, Diversity	Перед выкаткой, на сплите по времени. Порог: не хуже текущей модели
Онлайн-поведение	CTR блока, add-to-cart rate, конверсия в покупку из блока	Ежедневно, в разрезе блоков и сегментов (новые/старые)
Бизнес	Выручка (GMV) на пользователя, средний чек, число товаров в заказе, retention, доля продаж длинного хвоста и малых продавцов	A/B-тест, сравнение с контрольной группой (Trending)
Guardrail	Возвраты, жалобы, «скрыть рекомендацию», скорость загрузки страницы, нарушения политики (18+ детям)	Тест останавливают, если ухудшились, даже при росте выручки
Системные	Латентность p50/p95/p99, RPS, ошибки, **доля fallback-ответов**, попадание в кэш	Онлайн, алерты
Здоровье модели и данных	Возраст модели, свежесть данных, объём событий, дрейф распределений, coverage и доля топ-100 в выдаче	Ежедневно, алерт на скачки

9.2. Как измерять эффект

- **Только A/B-тест** против бейзлайна. Контроль — Trending, а не «без рекомендаций»: иначе мы измеряем ценность блока, а не модели.
- **Главная метрика — инкрементальная выручка на пользователя**, а не «доля выручки через рекомендации». Многие клики по рекомендациям — покупки, которые произошли бы и так (каннибализация поиска и каталога).
- Длительность от 2 недель (недельная сезонность), учёт эффекта новизны.
- Отдельный разрез по новым пользователям: холодный старт улучшается или нет.

9.3. Что бизнес ожидает и что получит на самом деле

Ожидание	Реальность
«+35% выручки, как у Amazon»	Цифра 35% — давняя консалтинговая оценка, а не результат A/B-теста. В опубликованных A/B-экспериментах реальный инкрементальный эффект обычно в единицах процентов
«ML сразу лучше текущей выдачи»	В нашем эксперименте каждая ML-модель по отдельности хуже Trending. Выигрыш дал только гибрид с эвристикой (+37% NDCG офлайн), и 80% его выдачи — те же хиты
«Персонализация для всех»	12% тестовых пользователей без истории, 43% покупок — новинки, которых модель не видела. Для них работает content-based и популярное
«Офлайн +37% = онлайн +37%»	Офлайн-прирост обычно не переносится один к одному, бывает и обратный знак. Нужен A/B
«Внедрили и забыли»	Нужны переобучение, мониторинг, фильтры, разбор жалоб: постоянная стоимость команды и инфраструктуры
«Рост продаж хитов»	Рекомендации усиливают хиты. Если цель — продажи длинного хвоста и малых продавцов, это надо явно закладывать в выдачу

Реалистичный результат для MVP: заметный прирост CTR и конверсии блоков по сравнению со случайным или просто популярным, единицы процентов к выручке на пользователя. Основная ценность — в блоках «с этим покупают» и «похожие» на карточке товара, где они увеличивают чек.

10. Как улучшить модель

1. **Валидация ближе к проду:** скользящее окно (обучение → неделя теста → дообучение) вместо одного теста длиной 13 месяцев; та же процедура — для проверки модели перед выкаткой.
2. **Новинки:** включить в оценку покупки новых товаров. Добавить в гибрид content-based кандидатов среди свежих товаров.
3. **Двухстадийная схема:** кандидаты (ALS, ItemKNN, content, AlsoBought, Trending) → ранжировщик на градиентном бустинге (CatBoost) с признаками пользователя, товара, цены, платформы и сезона.
4. **Контекстная популярность:** Trending по платформе пользователя (PS / Xbox / Switch / PC) вместо глобального. Ожидаемо снижает проблему «Zelda владельцу Xbox 360».
5. **Разнообразие:** MMR-переранжирование, лимит на бренд или серию в выдаче, дедупликация изданий одного тайтла.
6. **Больше сигналов:** просмотры, корзина, возвраты, «не интересно» в качестве негатива.
7. **Эмбеддинги текста** (sentence-transformers) вместо TF-IDF для похожих товаров, а для 27% товаров без описания — изображения.

11. Выводы

11.1. Что подтвердилось на практике

1. Реализованы 4 бизнес-эвристики, content-based, три коллаборативных подхода (UserKNN, ItemKNN, ALS из готовой библиотеки implicit) и гибрид. Всё работает на ноутбуке без GPU: полный цикл обучения, подбора весов гибрида и оценки всех моделей занимает около двух минут.
2. Главный практический урок: сильный бейзлайн. Неперсональная эвристика Trending обошла каждую ML-модель по отдельности, а лучший результат дал гибрид ML-моделей с этой эвристикой (+37% NDCG@10, веса подобраны на валидации).
3. Точность и разнообразие конфликтуют: лучший по точности гибрид покрывает 5% каталога, и 80% его выдачи — общие для всех хиты; менее точный покрывает 43%. Выбор между ними — бизнес-решение, принимается A/B-тестом.
4. Холодный старт в этих данных в первую очередь касается товаров (43% тестовых покупок — новинки), а не пользователей (12%). Коллаборативные модели здесь бессильны, нужны content-based и квоты на новинки.

5. Офлайн-метрики — только фильтр перед A/B-тестом. Реальный эффект для бизнеса меряется инкрементальной выручкой против бейзлайна, и обычно он заметно скромнее ожиданий.

11.2. Ограничения работы

Что	В чём ограничение
Тестовое окно	13 месяцев без переобучения модели: абсолютные метрики занижены, доля новинок завышена. Ближе к проду — скользящая валидация с окном в 1–2 недели
Каталог	ограничен товарами, у которых есть покупки: для нового товара без продаж «Похожие товары» в MVP не строятся, хотя content-based это позволяет
Сигнал	отзыв используется как замена покупки; просмотров, корзины и возвратов в данных нет
Эффект для бизнеса	не измерен: для этого нужен A/B-тест на реальном трафике (раздел 9)

12. Процесс разработки с ИИ-агентом

Работа выполнялась в режиме агентной разработки: код, эксперименты и этот отчёт сделаны ИИ-агентом по постановке и под контролем автора. Ниже описаны инструменты, модель, пайплайн и расход ресурсов.

12.1. Сетап

Компонент	Что использовалось
Агент	Claude Code, десктопное приложение
Модель	Claude Opus 5.5, уровень рассуждений medium
Режим	auto: агент сам выполняет команды и правит файлы, рискованные действия подтверждает пользователь
Инструменты агента	чтение и правка файлов, запуск команд оболочки, фоновые задачи для долгих загрузок, встроенная панель браузера, скиллы генерации .docx и построения графиков, инструменты управления сессиями (для сбора статистики этого раздела)
Среда	macOS, Apple M4 Pro, Python 3.12 в изолированном окружении
Контроль версий	git, репозиторий создавался и пушился вручную

12.2. Расход ресурсов

Работа заняла два чата (сессии агента). Расход посчитан по журналам сессий: для каждого ответа модели учтены входные токены, запись и чтение кэша контекста и выходные токены.

Показатель	Чат 1: реализация	Чат 2: ревью и отчёт	Всего
Дата, длительность	05.10.2026, 1,5 ч	11.10.2026, 9,5 ч	—
Сообщений пользователя	5	7	12
Запросов к модели	62	109	171

Показатель	Чат 1: реализация	Чат 2: ревью и отчёт	Всего
Вызовов инструментов	63	150	213
Входные токены (без кэша)	126	218	344
Запись в кэш контекста	134 877	581 650	716 527
Чтение из кэша контекста	7,40 млн	23,90 млн	31,31 млн
Выходные токены	81 486	140 355	221 841
Всего токенов	7,62 млн	24,63 млн	32,25 млн

Почти весь объём (97%) — повторное чтение контекста из кэша: на каждом шаге модель получает всю предыдущую переписку, поэтому кумулятивный расход в десятки раз больше размера самого контекста. Максимальный контекст второго чата — 376 918 токенов, 38% окна в 1 млн; автоматическое сжатие контекста не понадобилось ни разу. Тарифный план — Pro. Процент лимитов плана не приводится: в те же часы на этом аккаунте шла работа над другим проектом, и разделить расход по проектам нельзя.

Длительность второго чата указана от первого до последнего сообщения и включает паузы, пока автор проверял результаты и снимал скриншоты.

12.3. Пайплайн

Работа шла итерациями «поставить — реализовать — измерить — пересмотреть», а не одним проходом.

- **Постановка (чат 1).** Автор ограничил объём: MVP на ноутбуке, проблемы из части II разбираются теоретически, без реализации. Датасет агент предложил вопросом с вариантами, автор выбрал Amazon Video Games. Нужность API и Prometheus агент обсуждал с автором: API оставлен для демонстрации блоков витрины, Prometheus — нет.
- **Реализация (чат 1).** Загрузка данных в фоне, затем эвристики, content-based, коллаборативные модели, гибрид, офлайн-оценка и REST API. Каждая модель прогонялась на реальных данных сразу после написания.
- **Первый отчёт (чат 1).** Отчёт в .docx и графики сделаны с помощью скиллов агента.
- **Ревью (чат 2).** Отдельное ревью готовой работы на соответствие заданию нашло ошибки, которые в первом чате остались незамеченными: веса гибрида подбирались на тесте, гибрид на 80% повторял Trending, API падал на неверном параметре, в отчёте было неверное утверждение о новых товарах, не было PDF и ссылки на репозиторий (разделы 6.2 и 6.3).
- **Исправления (чат 2).** Подбор весов вынесен на валидацию, добавлена метрика TrendShare, оценка перезапущена, выводы переписаны по новым числам.
- **Отчётность (чат 2).** Отчёт переведён на генерацию скриптом из сохранённых метрик по образцу предыдущей работы автора, оформление приведено к единому виду. Скриншоты снимал автор по списку от агента.

12.4. Что оказалось трудным

- **Молчаливые ошибки оценки.** Гибрид давал +37% NDCG к Trending и выглядел успешным; то, что 80% его выдачи совпадает с Trending, обнаружилось только после введения отдельной метрики. Доля новых товаров в тесте после рефакторинга сначала посчиталась равной нулю, потому что функция разбиения уже отфильтровала эти товары. Ни то, ни другое не вызывало ошибку.
- **Замечание без исправления.** В первом чате агент сам записал подбор весов на тесте в ограничения работы, но не исправил это. Проверка свежим взглядом во втором чате оказалась полезнее, чем ожидалось.
- **Инструменты оформления.** LibreOffice игнорировал ширины колонок, заданные python-docx, а встроенный в LibreOffice Python система завершала при запуске. Оба случая решались проверкой готового PDF по страницам, а не по коду.

13. Репозиторий

https://github.com/Mapc27/devops-prime-era-rec-sys

13.1. Состав

```
README.md                    обзор проекта и инструкции запуска
requirements.txt             зависимости с зафиксированными версиями
scripts/download_data.sh     скачивание датасета в data/raw
recsys/data.py               загрузка, parquet-кэш, разбиение по времени
recsys/models.py             все модели с единым интерфейсом и общий контекст
recsys/metrics.py            метрики ранжирования и beyond-accuracy
recsys/evaluate.py           подбор весов гибрида и офлайн-сравнение моделей
recsys/api.py                REST API: по эндпоинту на каждый блок витрины
recsys/figures.py            графики для отчёта
reports/metrics.csv          метрики всех моделей
reports/data_stats.json      статистика датасета
reports/hybrid_weights.json  веса гибрида, подобранные на валидации
reports/figures/             графики, схема и скриншоты
reports/make_docx.py         сборка отчёта из сохранённых метрик
reports/RecSys_report.*      этот отчёт (.docx и .pdf)
```

13.2. Установка и запуск

```
python3.12 -m venv .venv
.venv/bin/pip install -r requirements.txt
./scripts/download_data.sh

# оценка: подбор весов гибрида и сравнение моделей
.venv/bin/python -m recsys.evaluate

# сервис, документация на http://localhost:8000/docs
.venv/bin/uvicorn recsys.api:app --port 8000

# отчёт
.venv/bin/python -m recsys.figures
.venv/bin/python reports/make_docx.py --pdf
```

13.3. Открытость стека

Компонент	Лицензия
implicit, FastAPI, python-docx, tabulate	MIT
NumPy, SciPy, pandas, scikit-learn, uvicorn	BSD
PyArrow	Apache 2.0
matplotlib	Matplotlib License (на основе PSF)
Датасет Amazon Reviews 2023	открытый набор данных, скачивается без регистрации

Платные подписки и облачные API не использовались, все вычисления выполняются локально.